2 INTRODUCTION

2.1 Contexte et Motivations

> *"It is the end for Leicester City in the Championship, ten years on from one of the greatest sporting achievements ever, the former champions of England are heading to lower league football. A sad, humiliating demise for a club that showed the world you can dream, they lived that dream. But look at them now."*

Cette phrase, prononcée par le commentateur sportif Peter Drury sur Sky Sports le 21 avril 2026, au soir de la relégation de Leicester City en troisième division anglaise, dépasse le simple cadre du match pour devenir une véritable narration du temps long. Celle-ci résume la trajectoire singulière d'un club qui a connu, en l'espace de quelques années, les sommets les plus inattendus et les chutes les plus brutales du football moderne.

Pour tout passionné de football, la saison 2015–2016 de Premier League demeure en effet une anomalie magnifique, un moment suspendu dans l'histoire du sport. Leicester City, club initialement promis à la lutte pour le maintien, a réussi l'impensable en devenant champion d'Angleterre devant Chelsea, Manchester City, Arsenal et Tottenham. Cet exploit, souvent décrit comme l'un des plus improbables de l'histoire du sport moderne, incarne une idée simple mais puissante : dans un système compétitif, même structuré et fortement déséquilibré, l'imprévisible peut advenir.

Ce qui rend cet épisode si marquant n'est pas seulement le titre en lui-même, mais ce qu'il symbolise. Leicester a, le temps d'une saison, transformé un scénario jugé quasi impossible en réalité tangible. They lived the dream. Cette phrase, devenue presque emblématique, traduit l'essence même de cet exploit : la réalisation d'un événement que la logique sportive et statistique tendait à exclure.

C'est précisément pourquoi explorer quantitativement la rareté de cet exploit est, pour tout passioné de football et de mathématiques, un exercice aussi intellectuellement stimulant qu'humainement parlant.

2.2 Objectif du travail

L'objectif de ce projet est de proposer un modèle probabiliste simple permettant d'estimer la probabilité de réalisation de certains événements rares dans un championnat de football. Nous nous intéressons en particulier à la saison 2015–2016 de Premier League et à la victoire inattendue de Leicester City.

Le travail repose sur un modèle de compétition de type Bradley–Terry. Chaque équipe est associée à une valeur intrinsèque positive, et la probabilité qu'une équipe batte une autre dépend du rapport entre leurs valeurs. À partir de ce modèle, nous simulons des saisons complètes et nous estimons plusieurs probabilités :

- la probabilité que Leicester gagne le championnat ;
- la probabilité que les deux clubs de Manchester restent hors du podium ;
- la probabilité que Chelsea et Liverpool manquent les places européennes.

Ces probabilités sont difficiles à calculer analytiquement, car le championnat contient un grand nombre de matchs et de classements possibles. Nous utilisons donc plusieurs méthodes numériques d'estimation :

- la méthode de Monte Carlo naïf ;
- l'échantillonnage préférentiel ;
- le splitting adaptatif multi-niveaux ;
- l'algorithme de la dernière particule, que nous ajoutons comme extension naturelle.

L'objectif final est de comparer ces méthodes en termes de stabilité, de coût de calcul et de précision.

3
MODÉLISATION DU CHAMPIONNAT

3.1 Modèle de Bradley–Terry

On considère un championnat composé de $N = 20$ équipes. Chaque équipe i est associée à une valeur intrinsèque positive

$$V_i > 0.$$

Lorsque deux équipes i et j s'affrontent, la probabilité que l'équipe i batte l'équipe j est donnée par le modèle de Bradley–Terry :

$$\mathbb{P}(i \text{ bat } j) = \frac{V_i}{V_i + V_j}.$$

Le modèle ne contient pas de match nul : chaque match admet un unique vainqueur. Les matchs sont supposés indépendants conditionnellement aux valeurs intrinsèques des équipes.

3.2 Format du championnat

Le championnat étudié suit un format aller-retour. Chaque paire d'équipes (i, j) se rencontre deux fois. Il y a donc

$$2\binom{20}{2} = 380$$

matchs au total.

Pour chaque match entre deux équipes i et j, on introduit une variable de Bernoulli :

$$X_{i,j}^{(k)} = \begin{cases} 1, & \text{si } i \text{ bat } j, \\ 0, & \text{si } j \text{ bat } i, \end{cases} \qquad k \in \{1, 2\}.$$

On a

$$\mathbb{P}(X_{i,j}^{(k)} = 1) = \frac{V_i}{V_i + V_j}.$$

3.3 Score final et classement

Le score final de l'équipe i est défini par

$$S_i = \sum_{j \neq i} \left(X_{i,j}^{(1)} + X_{i,j}^{(2)} \right).$$

Chaque victoire rapporte un point et chaque défaite rapporte zéro point. Le vainqueur du championnat est ensuite défini par

$$\texttt{winner(scores)} = \texttt{np.argmax(scores)}.$$

Ainsi, en cas d'égalité, l'équipe déclarée championne est celle qui apparaît le plus tôt dans la liste des clubs.

3.4 Choix des valeurs intrinsèques

Les valeurs intrinsèques sont construites à partir des points obtenus par les clubs lors de la saison précédente. Dans notre implémentation, on utilise

$$V_i = P_i^{\kappa},$$

où P_i désigne le nombre de points associé à l'équipe i et où $\kappa = 1.5$. Pour les équipes promues, les points de Championship sont ajustés avant l'application de la puissance κ.

Cette modélisation donne un avantage initial aux clubs ayant terminé haut au classement précédent, tout en laissant une probabilité non nulle aux événements inattendus, comme la victoire de Leicester.

4 ESTIMATION DE LA PROBABILITÉ QUE LEICESTER GAGNE

4.1 Formulation du problème

On cherche principalement à estimer

$$p_{\text{LEI}} = \mathbb{P}(\text{Leicester gagne le championnat}).$$

Dans le code, cet événement est défini par

$$A_{\text{LEI}} = \{\texttt{winner(scores)} = \texttt{LEI_IDX}\}.$$

L'événement est rare sous le modèle, car Leicester possède une valeur intrinsèque relativement faible par rapport aux grands clubs de Premier League. Une estimation directe nécessite donc un grand nombre de simulations pour obtenir une précision satisfaisante.

4.2 Méthode de Monte Carlo naïf

- **Principe**

  On simule n championnats indépendants sous la loi du modèle :

  $$\omega_1, \omega_2, \ldots, \omega_n \overset{\text{i.i.d.}}{\sim} \mathbb{P}_V,$$

  puis on compte la proportion de championnats dans lesquelles Leicester est champion, on considère alors l'estimateur de Monte Carlo naïf :

  $$\widehat{T}_A^{\text{MC}} = \frac{1}{n}\sum_{k=1}^{n} \mathbf{1}_A(\omega_k).$$

- **Propriétés de l'estimateur.**

  — **Sans biais :** $\mathbb{E}\left[\widehat{T}_A^{\text{MC}}\right] = \mathbb{P}(A)$.

  — **Variance :** $\text{Var}\left(\widehat{T}_A^{\text{MC}}\right) = \dfrac{\mathbb{P}(A)(1-\mathbb{P}(A))}{n}$.

  — **Convergence** par la loi des grands nombres : $\widehat{T}_A^{\text{MC}} \xrightarrow[n\to\infty]{\text{p.s.}} \mathbb{P}(A)$.

• Intervalle de confiance

Par le théorème central limite, un intervalle de confiance asymptotique de niveau 95 % est :

$$\mathrm{IC}_{95\%} \;=\; \widehat{T}_A^{\mathrm{MC}} \;\pm\; 1{,}96\,\sqrt{\frac{\widehat{T}_A^{\mathrm{MC}}\left(1-\widehat{T}_A^{\mathrm{MC}}\right)}{n}}.$$

• Limites

Coefficient de variation (CV). Pour un événement de petite probabilité $p = \mathbb{P}(A)$, la précision relative de l'estimateur, mesurée par le coefficient de variation, est :

$$\mathrm{CV}\left(\widehat{T}_A^{\mathrm{MC}}\right) \;=\; \frac{\sqrt{\mathrm{Var}\left(\widehat{T}_A^{\mathrm{MC}}\right)}}{\mathbb{E}\left[\widehat{T}_A^{\mathrm{MC}}\right]} \;=\; \sqrt{\frac{1-p}{np}} \;\xrightarrow{\;p\to 0\;}\; \frac{1}{\sqrt{np}}.$$

Pour atteindre une précision relative $\mathrm{CV} \le \varepsilon$, il faut

$$n \;\ge\; \frac{1-p}{p\,\varepsilon^2} \;\approx\; \frac{1}{p\,\varepsilon^2}.$$

Application numérique — victoire de Leicester. Avec $p \approx 8 \times 10^{-5}$ (estimé par MC naïf, cf. résultats numériques), le nombre de simulations nécessaires selon la précision visée est :

Précision cible	n **nécessaire**
$\mathrm{CV} \le 100\,\%$	$\approx 12\,500$
$\mathrm{CV} \le 50\,\%$	$\approx 50\,000$
$\mathrm{CV} \le 10\,\%$	$\approx 1\,250\,000$
$\mathrm{CV} \le 1\,\%$	$\approx 125\,000\,000$

Table 1 – Nombre de simulations Monte Carlo naïf nécessaires pour atteindre une précision relative donnée sur $\mathbb{P}$(Leicester gagne).

• Résultats numériques

Événement : victoire de Leicester. On applique l'estimateur Monte Carlo naïf à l'événement $A_1 = \{\text{Leicester est champion}\}$ avec $n = 50\,000$ simulations.

Événement	$\hat{p}$	**IC 95 %**	**Précision abs.**	**Hits**
Leicester champion (A_1)	$8{,}0 \times 10^{-5}$	$[1{,}6 \times 10^{-6},\ 1{,}6 \times 10^{-4}]$	$7{,}8 \times 10^{-5}$	4 / 50 000

Table 2 – Résultat du Monte Carlo naïf ($n = 50\,000$) pour l'événement « Leicester champion ».

Lecture de l'intervalle de confiance. L'IC 95 % couvre presque deux ordres de grandeur : p pourrait valoir aussi bien $1{,}6 \times 10^{-6}$ que $1{,}6 \times 10^{-4}$. Avec seulement 4 hits sur 50 000 simulations, l'estimateur est fondamentalement instable — ce résultat illustre directement les limites théoriques discutées dans le paragraphe précédent.

Étude de la convergence en n. Pour illustrer empiriquement la convergence de l'estimateur, on trace $\hat{p}(n)$ en fonction de n pour plusieurs seeds indépendants. La Figure 1 montre que :

- pour $n < 12\,500 \approx 1/p$, la majorité des runs affichent $\hat{p} = 0$ (aucun hit), ce qui constitue une estimation muette ;
- les premiers hits provoquent des bonds brutaux de l'estimateur ;
- les cinq trajectoires ne convergent pas vers la même valeur avant $n \approx 100\,000$, signe d'une variance résiduelle élevée.

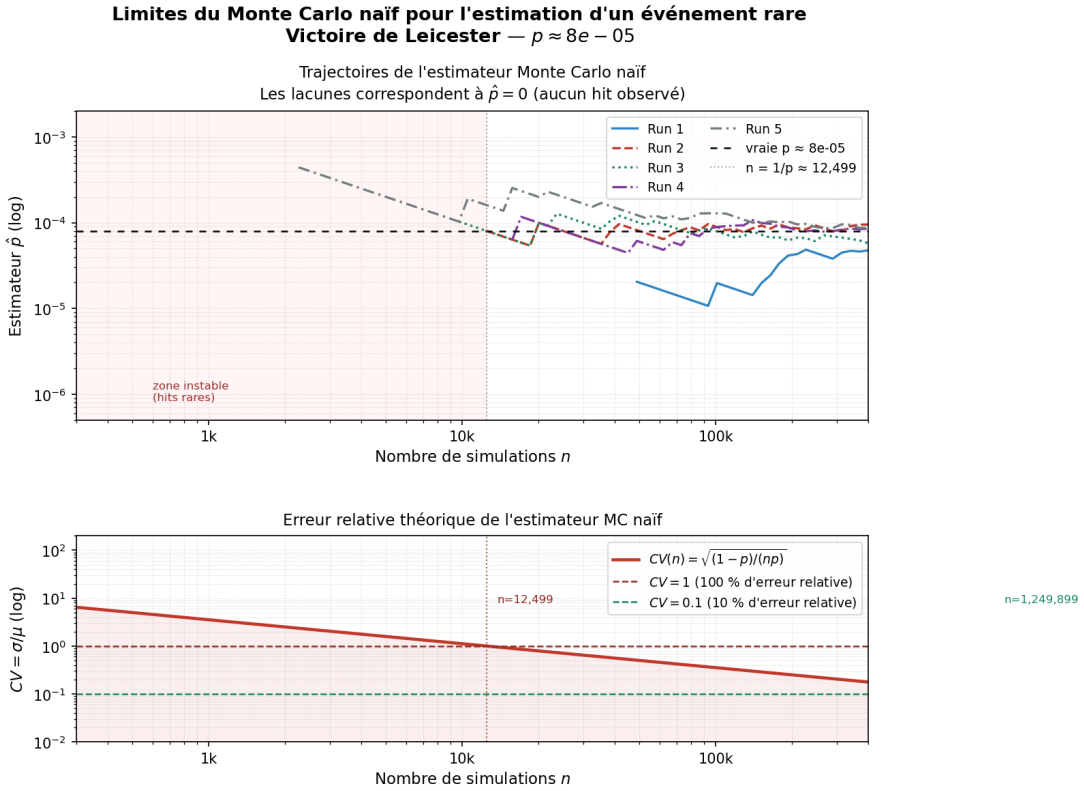


Figure 1 – Haut : cinq trajectoires indépendantes de $\hat{p}(n)$ (échelle log-log) ; les lacunes correspondent à $\hat{p} = 0$. Bas : coefficient de variation théorique $\mathrm{CV}(n) = \sqrt{(1-p)/(np)}$; les lignes pointillées marquent les seuils $\mathrm{CV} = 1$ et $\mathrm{CV} = 0{,}1$.

4.3 Échantillonnage préférentiel

- **Principe**

L'échantillonnage préférentiel consiste à modifier la loi de simulation afin de rendre l'événement rare plus fréquent. Dans notre cas, on augmente artificiellement la valeur intrinsèque de Leicester en introduisant un facteur de tilt $c > 1$. On définit alors une famille paramétrique de lois indexée par un scalaire $c > 1$. Pour un paramètre c donné, on modifie la force intrinsèque de Leicester uniquement :

$$V_i^{Q_c} = \begin{cases} c \cdot V_{\mathrm{Lei}} & \text{si } i = \mathrm{Lei}, \\ V_i & \text{sinon.} \end{cases}$$

Sous Q_c, les matchs restent indépendants et la probabilité que Leicester batte l'équipe j devient :

$$q_c(\text{Lei bat } j) \;=\; \frac{c\,V_{\text{Lei}}}{c\,V_{\text{Lei}} + V_j} \;>\; \frac{V_{\text{Lei}}}{V_{\text{Lei}} + V_j} \;=\; p(\text{Lei bat } j).$$

Pour $c > 1$, Leicester gagne plus souvent sous Q_c que sous P, ce qui augmente mécaniquement la fréquence des hits.

Structure de la loi Q_c. Un championnat ω est entièrement décrit par les résultats des $2\binom{N}{2} = 380$ matchs. Comme seuls les matchs impliquant Leicester sont modifiés, la loi Q_c s'écrit :

$$Q_c(\omega) \;=\; \underbrace{\prod_{\substack{(i,j)\,:\\ i\neq\text{Lei},\, j\neq\text{Lei}}} P(\text{résultat}_{ij})}_{\text{inchangé sous } Q_c} \;\times\; \underbrace{\prod_{j\neq\text{Lei}} \prod_{r=1}^{2} q_c\Big(X^{(r)}_{\text{Lei},j}\Big)}_{\text{modifié}}.$$

• Rapport de vraisemblance

Expression générale. L'estimateur IS repose sur le rapport de vraisemblance (likelihood ratio) :

$$L(\omega) \;=\; \frac{P(\omega)}{Q_c(\omega)}.$$

Puisque seuls les matchs impliquant Leicester diffèrent entre P et Q_c, les contributions des autres matchs se simplifient ($P = Q_c$ sur ces matchs) et le rapport de vraisemblance se réduit à :

$$L(\omega) \;=\; \prod_{j\neq\text{Lei}} \prod_{r=1}^{2} \frac{p\Big(X^{(r)}_{\text{Lei},j}\Big)}{q_c\Big(X^{(r)}_{\text{Lei},j}\Big)},$$

où, pour chaque match (r) entre Leicester et j :

$$\frac{p(X^{(r)} = x)}{q_c(X^{(r)} = x)} \;=\; \begin{cases} \dfrac{p_{\text{Lei},j}}{q_{\text{Lei},j}} & \text{si } x = 1 \text{ (Leicester gagne)},\\[2ex] \dfrac{1 - p_{\text{Lei},j}}{1 - q_{\text{Lei},j}} & \text{si } x = 0 \text{ (Leicester perd)}, \end{cases}$$

avec $p_{\text{Lei},j} = V_{\text{Lei}}/(V_{\text{Lei}} + V_j)$ et $q_{\text{Lei},j} = cV_{\text{Lei}}/(cV_{\text{Lei}} + V_j)$.

• Estimateur IS et ses propriétés

Définition de l'estimateur. On simule n championnats indépendants $\omega_1, \ldots, \omega_n \sim Q_c$ et on pose $w_k = \mathbf{1}_A(\omega_k) \cdot L(\omega_k)$. L'estimateur IS est :

$$\widehat{T}_A^{\text{IS}} \;=\; \frac{1}{n}\sum_{k=1}^{n} w_k \;=\; \frac{1}{n}\sum_{k=1}^{n} \mathbf{1}_A(\omega_k)\, L(\omega_k).$$

Sans biais.

$$\mathbb{E}_{Q_c}\Big[\widehat{T}_A^{\text{IS}}\Big] \;=\; \mathbb{E}_{Q_c}[\mathbf{1}_A(\omega)\, L(\omega)] \;=\; \mathbb{E}_{Q_c}\left[\mathbf{1}_A(\omega)\,\frac{P(\omega)}{Q_c(\omega)}\right] \;=\; \mathbb{E}_P[\mathbf{1}_A(\omega)] \;=\; \mathbb{P}(A).$$

Variance.

$$\mathrm{Var}_{Q_c}\Big(\widehat{T}_A^{\text{IS}}\Big) \;=\; \frac{1}{n}\left(\mathbb{E}_{Q_c}\big[w_k^2\big] - \mathbb{P}(A)^2\right) \;=\; \frac{1}{n}\left(\mathbb{E}_P[\mathbf{1}_A\, L] - \mathbb{P}(A)^2\right).$$

La variance est minimisée (nulle) par la loi optimale $Q^*(\omega) = P(\omega)\,\mathbf{1}_A(\omega)/\mathbb{P}(A)$, inaccessible car elle requiert $\mathbb{P}(A)$. Le paramètre c est donc choisi pour approcher Q^* au mieux dans la famille $\{Q_c,\, c > 0\}$.

Intervalle de confiance. En posant $\hat{\sigma}^2 = \frac{1}{n}\sum_k w_k^2 - \hat{p}^2$, un IC asymptotique de niveau 95 % est :

$$\widehat{T}_A^{\mathrm{IS}} \;\pm\; 1{,}96\,\sqrt{\frac{\hat{\sigma}^2}{n}}.$$

• Résultats numériques

IS scalaire — tilt de Leicester seul. On applique l'estimateur IS avec $c = 3$ (valeur approchée du tilt optimal, voir Section suivante sur le choix de c^*) à l'événement $A_1 = \{\text{Leicester est champion}\}$, avec $n = 50\,000$ simulations.

Méthode	c	$\hat{p}$	**IC 95 %**	**CV empirique**
MC naïf	1	$8{,}0 \times 10^{-5}$	$[1{,}6 \times 10^{-6},\ 1{,}6 \times 10^{-4}]$	$\approx 50\,\%$
IS	3	$1{,}197 \times 10^{-4}$	$[1{,}14 \times 10^{-4},\ 1{,}26 \times 10^{-4}]$	$\approx 6\,\%$

Table 3 – Comparaison MC naïf vs IS scalaire ($c = 3$, $n = 50\,000$) pour l'événement « Leicester champion ».

Le gain en précision est considérable : le CV passe de 50 % à $\approx$ 6 %, soit un facteur ≈ 8 de réduction de l'erreur relative. En termes de simulations équivalentes, atteindre CV = 6 % par MC naïf aurait nécessité $n \approx 1/(\hat{p} \times 0{,}06^2) \approx 3{,}5$ millions de simulations, contre 50 000 seulement avec l'IS — un gain d'un facteur ~ 70.

Cohérence avec le MC naïf. Les deux estimateurs sont compatibles : $8{,}0 \times 10^{-5}$ (MC naïf) appartient bien à l'IC IS $[1{,}14 \times 10^{-4},\ 1{,}26 \times 10^{-4}]$ à l'ordre de grandeur près, compte tenu du fait que l'IC MC naïf est extrêmement large ($[1{,}6 \times 10^{-6},\ 1{,}6 \times 10^{-4}]$) et ne permet pas de conclure. La valeur de référence à retenir est celle de l'IS, beaucoup plus précise.

• Choix optimal du paramètre de tilt c^*

L'efficacité de l'estimateur IS dépend crucialement du paramètre c. Un c trop faible laisse l'événement rare et génère peu de hits ; un c trop élevé surpondère Leicester, ce qui produit des rapports de vraisemblance L très petits et très variables. Il s'agit donc de trouver le *juste équilibre* minimisant la variance de l'estimateur.

Critère d'optimalité : le coefficient de variation On cherche c^* minimisant la variance relative de $\widehat{T}_A^{\mathrm{IS}}$, mesurée par le coefficient de variation empirique des poids $w_k = \mathbf{1}_A(\omega_k) \cdot L(\omega_k)$:

$$\mathrm{CV}(c) \;=\; \frac{\sqrt{\widehat{\mathrm{Var}}(w_k)}}{\bar{w}} \;=\; \frac{1}{\hat{p}}\sqrt{\frac{1}{n}\sum_{k=1}^{n}(w_k - \bar{w})^2}, \qquad c^* \;=\; \operatorname*{argmin}_{c>0}\ \mathrm{CV}(c).$$

Un CV faible indique des poids w_k concentrés autour de leur moyenne : l'estimateur est stable. Rappelons que la loi optimale théorique $Q^* = P(\cdot \mid A)$ atteindrait CV = 0, mais elle est inaccessible car elle requiert $\mathbb{P}(A)$.

• Méthode A — Recherche par grille (Grid Search)

Principe. On évalue $\mathrm{CV}(c)$ empiriquement pour une grille de valeurs $c \in \mathcal{G}$ distribuées de manière log-uniforme sur $[1, 100]$, en utilisant n_{pilot} simulations pour chaque c :

$$\mathcal{G} = \{c_1, \ldots, c_{20}\}, \quad c_\ell = 10^{\,(\ell-1)/19\times 2}, \quad \ell = 1, \ldots, 20.$$

On retient ensuite :

$$c^*_{\mathrm{GS}} \;=\; \operatorname*{argmin}_{c\in\mathcal{G}}\ \mathrm{CV}(c).$$

Résultats. Le grid search avec $n_{\text{pilot}} = 10\,000$ simulations par valeur de c identifie :

$$\boxed{c^*_{\text{GS}} \approx 3{,}36, \qquad \text{CV}(c^*_{\text{GS}}) \approx 4{,}84.}$$

La Figure 2 représente la courbe $c \mapsto \text{CV}(c)$ en échelle log-linéaire. On y observe un minimum net autour de $c \in [3, 4]$:

- Pour $c < 3$: trop peu de hits sous Q_c, les poids w_k sont essentiellement nuls sauf rares exceptions $\Rightarrow$ CV élevé.
- Pour $c > 10$: Leicester gagne presque tous ses matchs sous Q_c, mais les rapports de vraisemblance $L(\omega) \ll 1$ sont extrêmement concentrés près de zéro et très variables $\Rightarrow$ CV élevé.
- Pour $c \approx 3$: équilibre optimal entre fréquence des hits et stabilité des poids L.

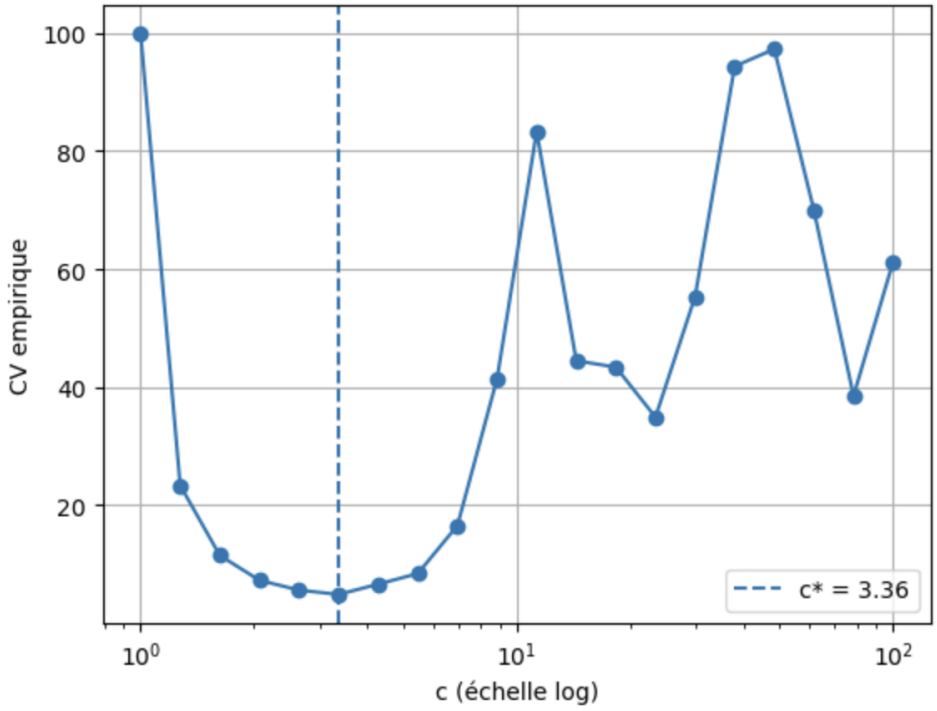


Figure 2 – Coefficient de variation empirique $\text{CV}(c)$ en fonction de c (échelle log-linéaire, $n_{\text{pilot}} = 10\,000$). Le minimum est atteint en $c^* \approx 3{,}36$ avec CV $\approx 4{,}84$.

Une recherche par grille effectuée sur l'intervalle $[1, 5]$ montre que le critère de validation croisée est minimal pour $c^\star \approx 3.32$ avec $\text{CV}(c) \approx 4.53$. On retient donc cette valeur comme paramètre optimal pour la suite de l'étude.

Limite du grid search. Cette approche est coûteuse ($20 \times n_{\text{pilot}}$ simulations) et sensible au pas de grille : un minimum entre deux points consécutifs peut être manqué. Elle ne fournit pas non plus de garantie théorique de convergence vers le vrai c^*.

• Méthode B — Algorithme de l'entropie croisée

Objectif théorique. L'algorithme de l'entropie croisée (CE) cherche c^* minimisant la divergence de Kullback-Leibler entre la loi optimale Q^* et la famille paramétrique $\{Q_c,\, c > 0\}$:

$$c^* \;=\; \operatorname*{argmin}_{c>0} \; KL(Q^* \,\|\, Q_c) \;=\; \operatorname*{argmin}_{c>0} \left\{ \mathbb{E}_{Q^*}[\log Q^*(\omega)] \;-\; \mathbb{E}_{Q^*}[\log Q_c(\omega)] \right\}.$$

Puisque le premier terme ne dépend pas de c, minimiser KL est équivalent à maximiser :

$$\mathcal{L}(c) \;=\; \mathbb{E}_{Q^*}[\log Q_c(\omega)] \;=\; \frac{1}{\mathbb{P}(A)}\,\mathbb{E}_P[\mathbf{1}_A(\omega)\,\log Q_c(\omega)]\,.$$

Reformulation par changement de mesure. L'espérance $\mathbb{E}_P[\mathbf{1}_A \log Q_c]$ est difficile à estimer sous P (événement rare). On l'évalue sous la loi courante $Q_c^{(t)}$ à l'itération t par un changement de mesure :

$$\mathcal{L}(c) \;\propto\; \mathbb{E}_{Q_c^{(t)}}\Big[\mathbf{1}_A(\omega)\,L^{(t)}(\omega)\,\log Q_c(\omega)\Big]\,, \qquad L^{(t)}(\omega) = \frac{P(\omega)}{Q_c^{(t)}(\omega)}.$$

On estime ceci sur n_{pilot} simulations :

$$\widehat{\mathcal{L}}(c) \;=\; \sum_{\substack{k=1\\ A(\omega_k)}}^{n_{\text{pilot}}} L_k^{(t)}\,\log Q_c(\omega_k),$$

où la somme porte uniquement sur les *hits* $\{\omega_k : A(\omega_k)\}$.

Expression de $\log Q_c(\omega_k)$. Puisque seuls les matchs impliquant Leicester sont modifiés entre P et Q_c, le terme $\log Q_c(\omega_k)$ se décompose en une constante (matchs sans Leicester, identiques sous P et Q_c) et la contribution des 38 matchs de Leicester :

$$\log Q_c(\omega_k) \;=\; \text{cste} \;+\; \sum_{j\neq \text{Lei}}\sum_{r=1}^{2}\left[X_{\text{Lei},j}^{(r)}\,\log\frac{cV_{\text{Lei}}}{cV_{\text{Lei}}+V_j} \;+\; (1-X_{\text{Lei},j}^{(r)})\,\log\frac{V_j}{cV_{\text{Lei}}+V_j}\right].$$

La maximisation de $\widehat{\mathcal{L}}(c)$ en c est donc un problème scalaire 1D, résolu numériquement par `minimize_scalar` sur $\log c$.

Algorithm 1 Entropie croisée pour l'optimisation de c

Initialisation : $c^{(0)} = c_{\text{init}}$ (ex : 10), graine fixée, n_{pilot}, n_{iter}
for $t = 0, 1, \ldots, n_{\text{iter}} - 1$ **do**
  Étape E — Simulation sous $Q_{c^{(t)}}$:
  for $k = 1, \ldots, n_{\text{pilot}}$ **do**
    Simuler $\omega_k \sim Q_{c^{(t)}}$, calculer $L_k^{(t)}$, enregistrer les outcomes des matchs de Leicester
    Si $A(\omega_k)$: stocker $(L_k^{(t)}, \omega_k)$ dans $\mathcal{H}$
  end for
  $\hat{p}^{(t)} \leftarrow \frac{1}{n_{\text{pilot}}} \sum_k \mathbf{1}_A(\omega_k)\, L_k^{(t)}$
  if $|\mathcal{H}| < 5$ **then**
    $c^{(t+1)} \leftarrow 3\,c^{(t)}$ ▷ trop peu de hits : augmenter c
    continuer
  end if
  Étape M — Maximisation de $\widehat{\mathcal{L}}(c)$:

$$c^{(t+1)} \;=\; \exp\left(\underset{\log c\,\in\,[0,\,\log 10^4]}{\operatorname{argmax}} \sum_{(L_k,\omega_k)\in\mathcal{H}} L_k\,\log Q_c(\omega_k)\right)$$

  (résolu par `minimize_scalar` sur $\log c$, méthode `bounded`)
end for
return $c^{(n_{\text{iter}})}$, historique $\{c^{(t)}, \hat{p}^{(t)}, \text{CV}^{(t)}\}$

Algorithme CE complet.

Convergence. La suite $(c^{(t)})$ converge vers :

$$c^* \;=\; \underset{c>0}{\operatorname{argmin}}\; KL(Q^* \,\|\, Q_c),$$

c'est-à-dire la meilleure approximation de Q^* dans la famille $\{Q_c\}$. Puisque la famille est unidimensionnelle, 4 à 6 itérations suffisent en pratique.

Résultats. On exécute l'algorithme CE avec $c^{(0)} = 10$, $n_{\text{pilot}} = 10\,000$ et $n_{\text{iter}} = 6$. On trouve $c^\star \approx 3{,}38$. Le Tableau 4 retrace la convergence.

Itération t	$c^{(t)}$	$\hat{p}^{(t)}$	$\text{CV}^{(t)}$	Hits
0	10,000	$1{,}59 \times 10^{-4}$	65,8	9621
1	3,214	$1{,}31 \times 10^{-4}$	5,9	2790
2	3,303	$1{,}31 \times 10^{-4}$	7,4	3011
3	3,271	$1{,}28 \times 10^{-4}$	5,2	2981
4	3,354	$1{,}27 \times 10^{-4}$	7,2	3185
5	3,314	$1{,}13 \times 10^{-4}$	5,9	3038

Table 4 – Historique de convergence de l'algorithme CE ($c^{(0)} = 10$, $n_{\text{pilot}} = 10\,000$).

Lecture de la convergence. L'itération 0 ($c = 10$) produit un CV élevé (65,8) car Leicester est trop avantagé : les rapports de vraisemblance L sont très variables. Dès l'itération 1, l'étape M identifie $c \approx 3{,}2$ et le CV chute à $\approx 5{,}9$, proche du minimum. Les itérations suivantes oscillent légèrement autour de $c \approx 3{,}2$–$3{,}3$, signe de convergence.

• Comparaison et choix final

Méthode	c^*	CV^*	$\hat{p}$ (50k sims)	**IC 95 %**
Grid Search	3,32	4,53	$1{,}22 \times 10^{-4}$	$[1{,}16 \times 10^{-4},\ 1{,}29 \times 10^{-4}]$
Entropie croisée	3,38	$\approx 5{,}9$	$1{,}23 \times 10^{-4}$	$[1{,}16 \times 10^{-4},\ 1{,}29 \times 10^{-4}]$

Table 5 – Comparaison des deux méthodes d'optimisation de c ($n = 50\,000$ simulations finales).

Les deux méthodes convergent vers la même région $c^* \in [3{,}2,\ 3{,}5]$, ce qui valide mutuellement les résultats. On retient $c^* \approx 3{,}32$ pour les estimations finales.

Interprétation physique de $c^* \approx 3{,}32$. Sous Q_{c^*}, la force intrinsèque de Leicester est multipliée par 3,32. Sa probabilité de victoire face à Chelsea devient :

$$q_{c^*}(\text{Lei bat Chelsea}) = \frac{3{,}32 \times V_{\text{Lei}}}{3{,}32 \times V_{\text{Lei}} + V_{\text{Che}}} \approx 0{,}61 \quad \text{au lieu de} \quad p(\text{Lei bat Chelsea}) \approx 0{,}32.$$

C'est le tilt minimal pour que Leicester gagne fréquemment ses matchs sans que les poids $L(\omega)$ ne deviennent trop variables : un équilibre entre *richesse en hits* et *stabilité des poids*.

Gain global de l'IS optimisé. En retenant $c^* \approx 3{,}32$ et $n = 50\,000$ simulations, on obtient un CV de $\approx 4{,}5\,\%$, contre $50\,\%$ pour le MC naïf avec le même budget. En termes de budget équivalent :

$$\frac{n_{\text{MC}}}{n_{\text{IS}}} \;\approx\; \left(\frac{\text{CV}_{\text{MC}}}{\text{CV}_{\text{IS}}}\right)^2 \;=\; \left(\frac{0{,}50}{0{,}056}\right)^2 \;\approx\; 123.$$

L'IS avec c^* est donc environ **123 fois plus efficace** que le MC naïf en termes de simulations nécessaires pour atteindre la même précision relative.

• Limites de l'IS scalaire sur les événements complexes :

Deux événements d'intérêt On distingue deux événements pour la saison 2015/2016 :

$$A_1 = \{\text{Leicester est champion}\},$$
$$A_2 = \left\{ \begin{array}{l} \text{Leicester champion} \\ \cap\ \text{Man City et Man United hors du podium} \\ \cap\ \text{Liverpool et Chelsea hors du top 7} \end{array} \right\}.$$

$A_2 \subset A_1$ est l'événement composite historiquement réalisé en 2015/2016 : il capture non seulement la victoire de Leicester, mais aussi l'effondrement simultané de tous les grands clubs.

Diagnostic : coefficient de variation et ESS On applique l'IS scalaire optimal ($c^* \approx 3{,}32$, calibré sur A_1) aux deux événements avec $n = 50\,000$ simulations.

Événement	$\hat{p}$	CV	ESS	ESS / n
A_1 : Leicester champion	$1{,}23 \times 10^{-4}$	6,26	$\approx 1\,240$	2,5 %
A_2 : événement complexe	$3{,}1 \times 10^{-6}$	94,58	≈ 6	≈ 0 %

Table 6 – IS scalaire ($c^* = 3{,}32$, $n = 50\,000$) sur A_1 et A_2. L'ESS (Effective Sample Size) est défini par $\text{ESS} = n/(1 + \text{CV}^2)$.

Le CV bondit de 6,26 à 94,58 entre A_1 et A_2 : l'IS scalaire, efficace pour A_1, devient quasiment inutile pour A_2. L'ESS tombe à ≈ 6 simulations *réellement informatives* sur 50 000 .

Instabilité des trajectoires La Figure 3 compare les trajectoires de $\hat{p}(n)$ pour les deux événements sur cinq runs indépendants.

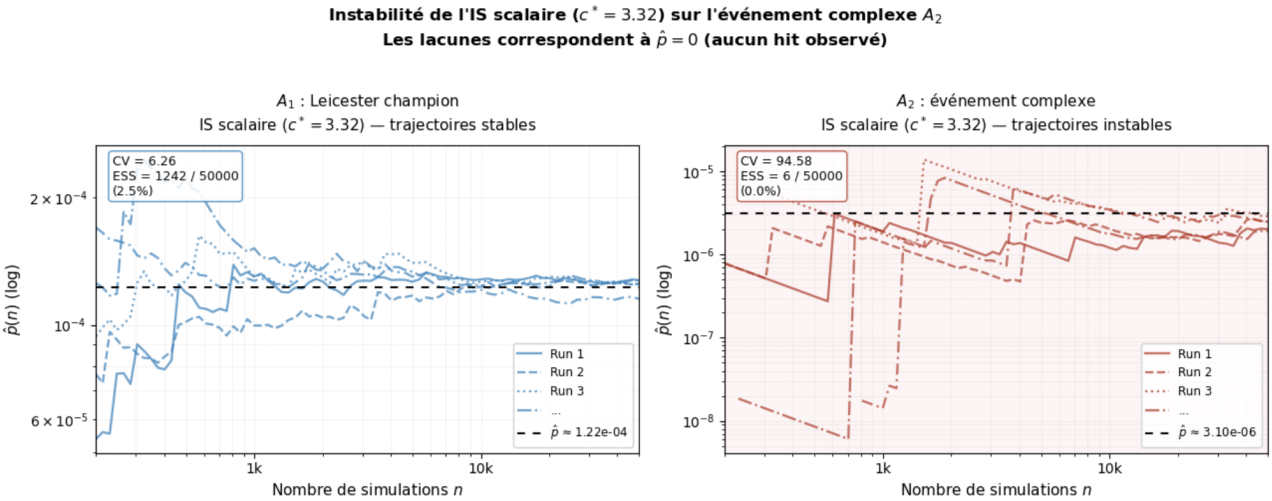


Figure 3 – Trajectoires de l'estimateur IS scalaire ($c^* = 3{,}32$, $n = 50\,000$) pour A_1 (gauche) et A_2 (droite), sur 5 runs indépendants. Les lacunes correspondent à $\hat{p} = 0$ (aucun hit observé). Pour A_1, les trajectoires convergent rapidement vers $\hat{p} \approx 1{,}23 \times 10^{-4}$ avec peu de dispersion. Pour A_2, les trajectoires restent erratiques sur tout l'intervalle, avec de larges lacunes et une forte dispersion entre runs (CV = 94,58, ESS ≈ 6 / 50 000).

- **Explication structurelle**

Le paramètre c^* est calibré pour minimiser $\mathrm{CV}(A_1)$ en multipliant la force de Leicester par $c^* \approx 3{,}32$. Sous Q_{c^*}, la probabilité que Leicester remporte chacun de ses matchs est significativement augmentée, ce qui favorise directement la réalisation de A_1.

Ce que le tilt scalaire ne fait pas. On peut décomposer $A_2 = A_1 \cap B$ avec

$$B \;=\; \big\{\text{Man City, Man United hors podium } \cap \text{ Liverpool, Chelsea hors top 7}\big\}.$$

Le tilt scalaire ne modifie aucun match entre ces équipes : leurs probabilités de victoire mutuelles sont identiques sous P et sous Q_{c^*}. Par conséquent :

$$Q_{c^*}(A_2) \;=\; Q_{c^*}(A_1) \cdot Q_{c^*}(B \mid A_1) \;\approx\; Q_{c^*}(A_1) \cdot P(B \mid A_1).$$

Si $P(B \mid A_1)$ est petite — les gros clubs s'effondrent rarement même quand Leicester gagne — alors A_2 demeure rare sous Q_{c^*}, et l'estimateur reste instable malgré le tilt.

Bilan : L'IS scalaire atteint ses limites dès que l'événement cible implique des conditions sur plusieurs équipes simultanément. Le tilt scalaire ne dispose que d'un seul degré de liberté — la force de Leicester — et ne peut pas agir sur la composante B de A_2.

Pour surmonter cette limite, il est nécessaire d'étendre le tilt à un **vecteur** $\mathbf{c} \in \mathbb{R}^N_{>0}$ agissant simultanément sur Leicester *et* sur ses concurrents directs. C'est l'objet de la section suivante.

4.4 Extension vectorielle de l'échantillonage préférentiel : renforcer Leicester et affaiblir les adversaires

- **Principe**

On définit un vecteur de tilt $\mathbf{c} = (c_1, \ldots, c_N) \in \mathbb{R}^N_{>0}$ et la loi de proposition $Q_{\mathbf{c}}$ par les forces modifiées :

$$V_i^{Q_{\mathbf{c}}} \;=\; c_i \cdot V_i, \qquad i = 1, \ldots, N.$$

Sous $Q_{\mathbf{c}}$, la probabilité que l'équipe i batte l'équipe j vaut :

$$q_{\mathbf{c}}(i \text{ bat } j) \;=\; \frac{c_i\, V_i}{c_i\, V_i + c_j\, V_j}.$$

On note que si $c_i = c_j$, le rapport $c_i/c_j = 1$ et cette probabilité coïncide avec $p(i \text{ bat } j)$ sous P : seuls les matchs entre équipes de coefficients différents sont modifiés.

- **Rapport de vraisemblance.**

Contrairement au cas scalaire où seuls les matchs de Leicester contribuaient au rapport de vraisemblance L, ici *tous les matchs* (i, j) avec $c_i \neq c_j$ contribuent. Pour éviter les underflows numériques liés au produit de 380 facteurs, on accumule en log :

$$\log L(\omega) \;=\; \log \frac{P(\omega)}{Q_{\mathbf{c}}(\omega)} \;=\; \sum_{i<j} \sum_{r=1}^{2} \log \frac{p\Big(X_{ij}^{(r)}\Big)}{q_{\mathbf{c}}\Big(X_{ij}^{(r)}\Big)},$$

où pour chaque match (r) entre i et j :

$$\log \frac{p(X^{(r)} = x)}{q_{\mathbf{c}}(X^{(r)} = x)} \;=\; \begin{cases} \log p_{ij} - \log q_{ij}^{\mathbf{c}} & \text{si } x = 1, \\ \log(1 - p_{ij}) - \log(1 - q_{ij}^{\mathbf{c}}) & \text{si } x = 0, \end{cases}$$

puis $L(\omega) = \exp(\log L(\omega))$.

• Paramétrisation structurée en trois groupes

Un vecteur $\mathbf{c} \in \mathbb{R}^{20}$ est un espace de recherche de dimension 20, difficile à optimiser. On exploite la structure du problème en regroupant les équipes selon leur impact sur les événements A_1 et A_2.

Définition des groupes.

- **Groupe 0 — Leicester** (1 équipe) : $c_{\text{Lei}} > 1$, on le renforce.
- **Groupe 1 — Gros favoris** (5 équipes : Chelsea, Man City, Arsenal, Man United, Tottenham) : $c_{\text{big}} < 1$, on les affaiblit. Ce sont les principaux concurrents de Leicester pour le titre.
- **Groupe 2 — Clubs moyens** (5 équipes : Liverpool, Southampton, Swansea, Stoke, Crystal Palace) : $c_{\text{mid}} \lesssim 1$, impact modéré.
- **Groupe 3 — Petites équipes** (9 équipes restantes) : $c = 1$, pas de tilt (impact négligeable sur l'événement).

Le vecteur de tilt est donc entièrement déterminé par $\boldsymbol{\theta} = (c_{\text{Lei}},\, c_{\text{big}},\, c_{\text{mid}}) \in \mathbb{R}^3_{>0}$, ce qui réduit la dimension de 20 à 3.

Cette réduction est motivée par la structure du modèle Bradley-Terry : la victoire de Leicester dépend avant tout de sa force relative par rapport aux gros favoris. Les petites équipes (Newcastle, Sunderland, Aston Villa, ...) ne menacent pas Leicester pour le titre ; leur tilt n'apporterait qu'une correction négligeable au rapport de vraisemblance.

• Résultats numériques

On applique le tilt vectoriel à deux groupes avec $c_{\text{Lei}} = 3{,}32$ (inchangé par rapport au scalaire) et $c_{\text{big}} = 0{,}70$, en conservant $c_i = 1$ pour les 14 équipes restantes.

Méthode	Événement	$\hat{p}$	CV	ESS	IC 95 %
IS vectoriel ($c_{\text{Lei}} = 3{,}32,\ c_{\text{big}} = 0{,}70$)	A_1 : Leicester champion	$1{,}19 \times 10^{-4}$	9,49	549	$[1{,}09,\ 1{,}29] \times 10^{-4}$
	A_2 : événement complexe	$2{,}24 \times 10^{-6}$	32,24	48	$[1{,}61,\ 2{,}88] \times 10^{-6}$

Table 7 – Résultats IS vectoriel à deux groupes ($n = 50\,000$). L'ESS est calculé par $n\,/\,(1 + \text{CV}^2)$.

Lecture des résultats.

- **Sur** A_1 : les deux méthodes sont quasi-équivalentes ($\hat{p}$ compatibles, CV similaires) (voir le paragraphe limites de l'IS scalaire). Le tilt vectoriel ne dégrade pas l'estimation de l'événement simple — les poids supplémentaires apportés par les 190 matchs sans Leicester restent proches de 1.

- **Sur** A_2 : un gain visible et important. Le CV passe de ($94{,}58 \to 32{,}24$) et l'ESS de ($6 \to 48$). Ce gain, bien que réel, reste décevant au regard de l'effort supplémentaire consenti : le tilt vectoriel mobilise les 380 matchs du championnat dans le calcul du rapport de vraisemblance, contre seulement 38 pour le scalaire.

- **Conclusion** : Ces résultats montrent que choisir $\mathbf{c}$ à la main, même avec une intuition physique raisonnable, ne suffit pas : $c_{\text{big}} = 0{,}70$ est vraisemblablement trop agressif, et le vrai optimum dans la famille $Q_{\mathbf{c}}$ reste à identifier. La question naturelle est donc : quelle valeur de $(c_{\text{Lei}}, c_{\text{big}}, c_{\text{mid}})$ minimise réellement le CV sur A_2 ? C'est précisément l'objet de la section suivante, consacrée à l'optimisation par entropie croisée vectorielle.

Illustration : trajectoires sur A_2. La Figure 4 montre les trajectoires de $\hat{p}(n)$ pour A_2 avec l'IS vectoriel, sur 5 runs indépendants.

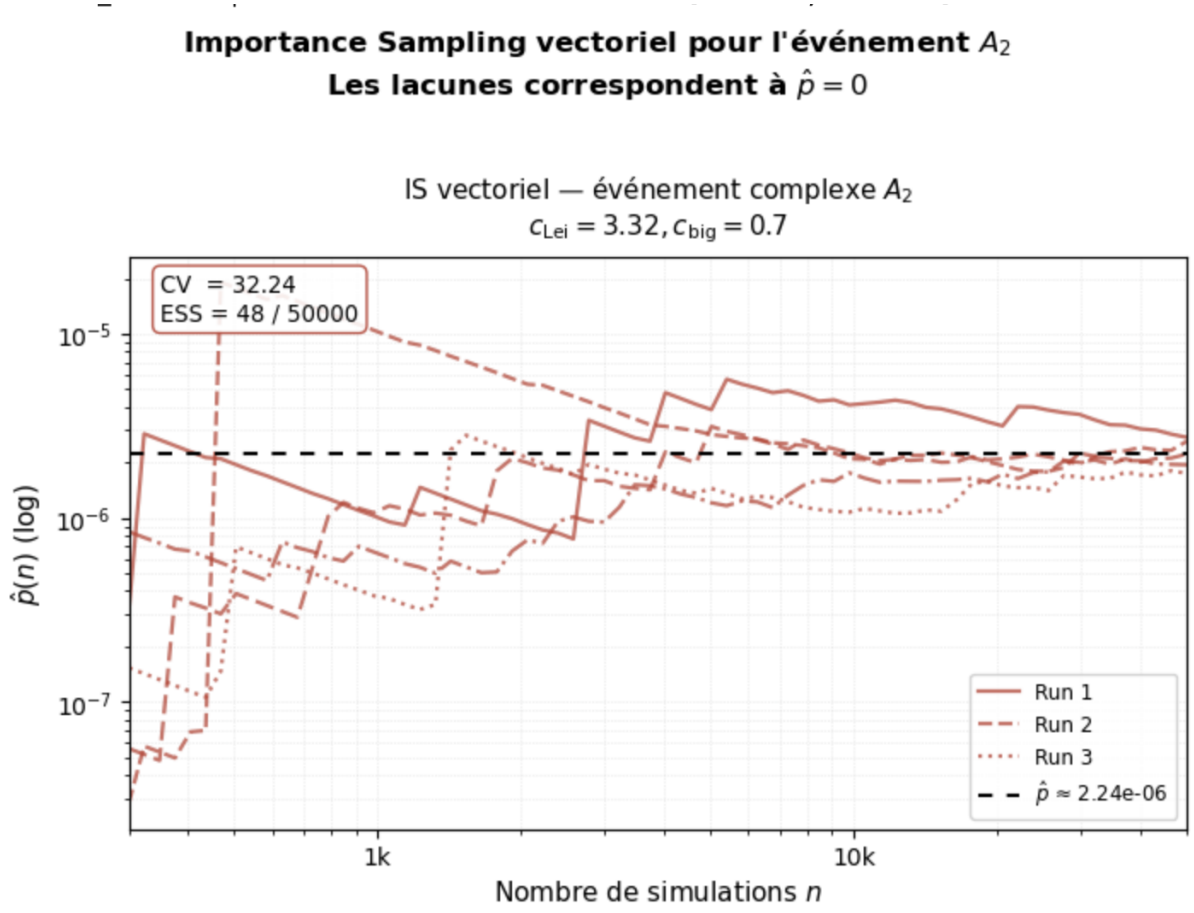


Figure 4 – Trajectoires de l'estimateur IS vectoriel ($c_{\text{Lei}} = 3{,}32$, $c_{\text{big}} = 0{,}70$) — pour A_2 ($n = 50\,000$, 5 runs indépendants). — trajectoires nettement plus stables, lacunes réduites, convergence visible (CV = 32,24, ESS ≈ 48).

- Optimisation par entropie croisée vectorielle

Objectif. On cherche :

$$\boldsymbol{\theta}^* \;=\; \operatorname*{argmin}_{\boldsymbol{\theta}} \; KL\big(Q^* \,\|\, Q_{\mathbf{c}(\boldsymbol{\theta})}\big)\,,$$

où $\mathbf{c}(\boldsymbol{\theta})$ est construit par la paramétrisation structurée ci-dessus.

Étape M — problème d'optimisation 3D. La fonction objectif de l'étape M devient :

$$\boldsymbol{\theta}^{(t+1)} \;=\; \operatorname*{argmax}_{\boldsymbol{\theta}} \sum_{\substack{k=1 \\ A(\omega_k)}}^{n_{\text{pilot}}} L_k^{(t)} \;\log Q_{\mathbf{c}(\boldsymbol{\theta})}(\omega_k),$$

où $\log Q_{\mathbf{c}(\boldsymbol{\theta})}(\omega_k)$ porte maintenant sur *tous* les matchs du championnat ω_k :

$$\log Q_{\mathbf{c}}(\omega_k) \;=\; \sum_{i<j} \sum_{r=1}^{2} \Big[X_{ij,k}^{(r)} \,\log q_{ij}^{\mathbf{c}} \;+\; (1 - X_{ij,k}^{(r)}) \,\log(1 - q_{ij}^{\mathbf{c}}) \Big]\,.$$

La maximisation en $\boldsymbol{\theta}$ est un problème 3D non linéaire, résolu par la méthode `L-BFGS-B` sur $\log \boldsymbol{\theta}$ (paramétrage en log pour garantir $\boldsymbol{\theta} > 0$).

Algorithm 2 Entropie croisée vectorielle pour l'optimisation de $\boldsymbol{\theta} = (c_{\text{Lei}}, c_{\text{big}}, c_{\text{mid}})$

Init : $\boldsymbol{\theta}^{(0)}$, n_{pilot}, n_{iter}, bornes $[0.05,\ 50]$ sur chaque composante
for $t = 0, 1, \ldots, n_{\text{iter}} - 1$ **do**
  $\mathbf{c}^{(t)} \leftarrow$ `make_c_structured`$(\boldsymbol{\theta}^{(t)})$
  Étape E : Simuler $\omega_1, \ldots, \omega_{n_{\text{pilot}}} \sim Q_{\mathbf{c}^{(t)}}$, calculer $L_k^{(t)}$, enregistrer tous les outcomes ω_k
  $\mathcal{H} \leftarrow \{(L_k^{(t)}, \omega_k) : A(\omega_k)\}$
  if $|\mathcal{H}| < 10$ **then**
    $c_{\text{Lei}}^{(t+1)} \leftarrow 3\, c_{\text{Lei}}^{(t)}$ ▷ trop peu de hits
    continuer
  end if
  Étape M :

$$\log \boldsymbol{\theta}^{(t+1)} \leftarrow \underset{\log \boldsymbol{\theta}}{\operatorname{argmax}} \sum_{(L_k, \omega_k) \in \mathcal{H}} L_k \ \log Q_{\mathbf{c}(\boldsymbol{\theta})}(\omega_k)$$

  (résolu par `L-BFGS-B`, 200 itérations max)
  $\boldsymbol{\theta}^{(t+1)} \leftarrow \text{clip}\Big(\exp(\log \boldsymbol{\theta}^{(t+1)}),\ 0.05,\ 50\Big)$
end for
return $\boldsymbol{\theta}^{(n_{\text{iter}})}$, historique

Algorithme CE vectoriel.

• Résultats numériques

Convergence de l'algorithme CE vectoriel. On initialise à $\boldsymbol{\theta}^{(0)} = (10,\ 0{,}5,\ 0{,}7)$ et on exécute 7 itérations avec $n_{\text{pilot}} = 10\,000$.

t	c_{Lei}	c_{big}	c_{mid}	$\hat{p}^{(t)}$	$\text{CV}^{(t)}$	Hits
0	10,000	0,500	0,700	$1{,}90 \times 10^{-8}$	45,92	589
1	3,429	0,555	0,761	$9{,}70 \times 10^{-7}$	39,84	347
2	3,013	0,705	0,878	$1{,}14 \times 10^{-6}$	**20,29**	110
3	2,587	0,641	0,863	$7{,}02 \times 10^{-7}$	21,55	95
4	2,631	0,642	0,885	$3{,}43 \times 10^{-6}$	32,41	117
5	2,991	0,782	1,007	$3{,}07 \times 10^{-6}$	25,20	54
6	2,839	0,770	1,105	$1{,}19 \times 10^{-6}$	24,90	54

Table 8 – Historique de convergence de l'algorithme CE vectoriel appliqué à A_2 ($\boldsymbol{\theta}^{(0)} = (10,\ 0{,}5,\ 0{,}7)$, $n_{\text{pilot}} = 10\,000$). Le meilleur CV (**20,29**) est atteint à l'itération 2.

Lecture des résultats. Plusieurs observations se dégagent :

— **Correction rapide de l'initialisation.** L'initialisation $c_{\text{Lei}} = 10$ est délibérément agressive : elle garantit suffisamment de hits dès l'itération 0 (589 hits) pour que l'étape M dispose d'un signal exploitable. Dès l'itération 1, c_{Lei} chute de 10 à 3,43, valeur proche du tilt scalaire optimal ($\approx 3{,}3$), confirmant la robustesse de ce paramètre.

— **Meilleur CV à l'itération 2.** L'itération 2 atteint le CV minimal de **20,29** avec $\boldsymbol{\theta} = (3{,}01,\ 0{,}71,\ 0{,}88)$. C'est un gain d'un facteur $\approx 4{,}5$ par rapport à l'IS scalaire sur A_2 ($\text{CV}_{\text{scalaire}} = 94{,}58$). En termes de budget équivalent, ce CV de 20,3 aurait nécessité $n \approx 20\,000 \times (44{,}71/20{,}29)^2 \approx 434\,000$ simulations avec l'IS scalaire.

— **Oscillations après l'itération 2.** À partir de l'itération 3, le nombre de hits chute fortement (95, 117, puis 54). L'étape M optimise alors sur un signal trop bruité, ce qui provoque des oscillations des para-

mètres et une dégradation du CV ($20{,}3 \to 32{,}4 \to 25{,}2 \to \dots$). Ce phénomène s'explique par la rareté intrinsèque de A_2 ($\hat{p} \approx 10^{-6}$) : avec $n_{\text{pilot}} = 10\,000$, le taux de hits sous $Q_{\boldsymbol{\theta}}$ est de l'ordre de 0,5–1 % seulement.

— **Limite structurelle de la famille $\{Q_{\mathbf{c}}\}$.** Même à l'itération 2 (meilleur point), le CV résiduel de 20,3 reste élevé. Une cause identifiée : les matchs entre gros clubs ($c_i = c_j = c_{\text{big}}$) ont la même loi sous P et sous $Q_{\mathbf{c}}$, car les facteurs c_{big} se simplifient. Or ce sont précisément ces matchs qui conditionnent l'effondrement des gros clubs au classement — composante centrale de A_2. La famille paramétrique choisie ne peut pas agir sur ce levier, ce qui constitue une limite intrinsèque indépendante de l'algorithme d'optimisation.

• Optimisation par descente de coordonnées

Principe. La recherche par grille en dimension $N = 20$ est computationnellement hors de portée : tester g valeurs par coordonnée représenterait g^{20} évaluations. On adopte une stratégie de **descente de coordonnées** : à chaque étape, une seule composante c_k est optimisée par grid search sur une grille 1D, toutes les autres étant fixées. On parcourt les N coordonnées dans un ordre structuré (Leicester en premier, puis les gros clubs, puis les clubs moyens et petits), et on répète ce cycle sur plusieurs itérations.

Formellement, à l'itération t et pour la coordonnée k :

$$c_k^{(t+1)} \;=\; \underset{c_k \in \mathcal{G}_k}{\operatorname{argmin}}\; \mathrm{CV}\Big(c_1^{(t+1)}, \dots, c_{k-1}^{(t+1)}, c_k, c_{k+1}^{(t)}, \dots, c_N^{(t)}\Big),$$

où $\mathcal{G}_k$ est une grille 1D adaptée au rôle de l'équipe k :

— $\mathcal{G}_{\text{Lei}} = [1,\ 10]$ (échelle log, $g = 10$ valeurs) : Leicester doit être renforcé.

— $\mathcal{G}_k = [0{,}3,\ 1{,}0]$ (échelle linéaire, $g = 10$ valeurs) pour $k \neq$ Lei : les adversaires sont affaiblis ou laissés inchangés.

Le critère minimisé est le CV^2 empirique estimé sur $n_{\text{sims}} = 20\,000$ simulations par point de grille.

Coût computationnel. Chaque itération évalue $N \times g = 20 \times 10 = 200$ points de grille, chacun nécessitant 20 000 simulations IS, soit $200 \times 20\,000 = 4 \times 10^6$ simulations par itération. Sur 5 itérations, le coût total est de 2×10^7 simulations — raisonnable et sans commune mesure avec les 10^{20} d'un grid search exhaustif en dimension 20.

Résultats : convergence des paramètres. Le Tableau 4.4 présente les valeurs convergées de $\mathbf{c}^*$ pour les équipes les plus significatives, après 5 itérations.

Équipe	**Groupe**	$c^{(1)}$	$c^{(2)}$	$c^{(3)}$	$c^{(4)}$	$c^{(5)}$
Leicester	cible	2,7826	2,7826	2,7826	2,7826	2,7826
Chelsea	gros	0,7667	0,7667	0,6889	0,6889	0,7667
Man City	gros	0,7667	0,7667	0,8444	0,8444	0,8444
Arsenal	gros	0,9222	0,8444	0,9222	0,8444	0,8444
Man United	gros	0,9222	0,9222	0,9222	0,9222	0,9222
Tottenham	gros	1,0000	0,9222	1,0000	0,9222	0,9222
Liverpool	moyen	1,0000	0,9222	0,8444	0,9222	1,0000
Southampton	moyen	0,9222	0,9222	0,9222	0,9222	0,9222
Newcastle	petit	1,0000	1,0000	0,9222	1,0000	1,0000
Norwich	petit	1,0000	1,0000	1,0000	0,9222	1,0000

Table 9 – Convergence des paramètres c sur 5 itérations (sélection d'équipes représentatives).

Valeurs de c_k par itération de la descente de coordonnées, pour les équipes les plus significatives ($n_{\text{sims}} = 20\,000$, $g = 10$, événement A_2).

Analyse des résultats. Trois observations se dégagent :

— **Convergence immédiate et stable de $c_{\mathbf{Lei}}$.** Leicester est fixé à $c_{\text{Lei}} = 2{,}783$ dès l'itération 1 et n'en bouge plus sur l'ensemble des 5 itérations. Ce résultat est cohérent avec le tilt scalaire optimal ($c^* \approx 3{,}3$) : le renforcement optimal de Leicester est peu sensible au tilt appliqué aux adversaires.

— **Affaiblissement modéré et stable des gros clubs.** Chelsea converge vers $c \approx 0{,}69$–$0{,}77$, Man City vers 0,84, Arsenal vers 0,84–0,92, Man United et Tottenham vers 0,92. Les oscillations résiduelles (ex : Chelsea entre 0,69 et 0,77) restent confinées à un pas de grille ($\Delta c = 0{,}078$).

— **Clubs moyens quasi-inchangés.** Southampton est parfaitement stable à 0,922 sur toutes les itérations. Liverpool oscille entre 0,844 et 1,000, ce qui indique que son tilt optimal est proche de 1 : l'algorithme hésite entre un léger affaiblissement et l'absence de tilt, signe que la contribution de Liverpool à l'événement A_2 est marginale.

— **Petites équipes non tilté.** Newcastle et Norwich restent à $c \approx 1{,}000$ sur l'ensemble des itérations (à un pas de grille près). Cela confirme que l'affaiblissement des petites équipes n'améliore pas le CV sur A_2 : ces équipes n'étant pas en compétition directe avec Leicester pour le titre, leur tilt n'agit pas sur la composante B de A_2.

Conclusion. La descente de coordonnées avec $n_{\text{sims}} = 20\,000$ fournit un vecteur optimal exploitable, avec une estimation finale de $\mathbb{P}(A_2)$ donnée par :

$$\hat{p} \;=\; 1{,}74 \times 10^{-6}, \qquad \text{CV} \;=\; 22{,}69, \qquad \text{IC}_{95\%} \;=\; [1{,}19 \times 10^{-6},\; 2{,}28 \times 10^{-6}].$$

Ce résultat est cohérent avec celui obtenu par la CE vectorielle structurée à la section précédente, qui atteignait un CV minimal de 20,29 — soit le même ordre de grandeur. Les deux méthodes convergent donc vers la même conclusion : avec la famille paramétrique $\{Q_{\mathbf{c}}\}$ choisie, le CV minimal atteignable sur A_2 se situe autour de 20–23.

4.5 Méthode de splitting adaptatif multi-niveaux

- **Principe**

On cherche toujours à estimer

$$p_{\text{LEI}} = \mathbb{P}(\text{Leicester gagne le championnat}).$$

Comme dans les sections précédentes, un championnat complet est représenté par l'ensemble des résultats des 380 matchs. On note cet état

$$X \in \{0,1\}^{380}.$$

La méthode de splitting consiste à ne pas estimer directement l'événement rare

$$A = \{\text{Leicester champion}\},$$

mais à introduire une suite d'événements emboîtés plus faciles à atteindre.

Pour cela, on utilise une fonction de progression $\phi(X)$ telle que

$$A = \{\phi(X) \geq 0\}.$$

Dans notre cas, $\phi(X)$ mesure l'avance de Leicester sur ses concurrents.

On définit alors des niveaux

$$a_1 < a_2 < \cdots < a_K < 0$$

et des événements

$$A_k = \{\phi(X) \geq a_k\}.$$

On a donc

$$A = \{\phi(X) \geq 0\} \subset A_K \subset \cdots \subset A_1.$$

La probabilité recherchée s'écrit alors

$$\mathbb{P}(A) = \mathbb{P}(A_1) \prod_{k=1}^{K-1} \mathbb{P}(A_{k+1} \mid A_k)\, \mathbb{P}(A \mid A_K).$$

Dans un splitting classique, les niveaux a_k doivent être fixés à l'avance. Ce choix est délicat : si deux niveaux successifs sont trop éloignés, la probabilité conditionnelle reste rare ; s'ils sont trop proches, le nombre de niveaux augmente inutilement.

Pour éviter un choix manuel, nous construisons les niveaux par quantiles empiriques. On fixe

$$u = \texttt{seuil}.$$

Dans nos simulations, on prend

$$u = 0.1.$$

À chaque étape, à partir d'un échantillon de valeurs

$$\phi(X_1), \ldots, \phi(X_n),$$

on trie ces valeurs et on choisit le quantile empirique d'ordre $1 - u$:

$$a_{k+1} = \phi_{(\lceil n(1-u) \rceil)}.$$

Ainsi, environ une proportion u des championnats dépasse le niveau suivant, ce qui donne l'approximation

$$\mathbb{P}(A_{k+1} \mid A_k) \simeq u.$$

La Figure 5 illustre cette construction pour $u = 0.1$, $n = 50000$ et $T = 50$. Les niveaux obtenus sont

$$-9,\ -6,\ -3,\ -1,\ 0.$$

Ils forment une suite croissante qui rapproche progressivement les simulations de l'événement final $\{\phi(X) \geq 0\}$.

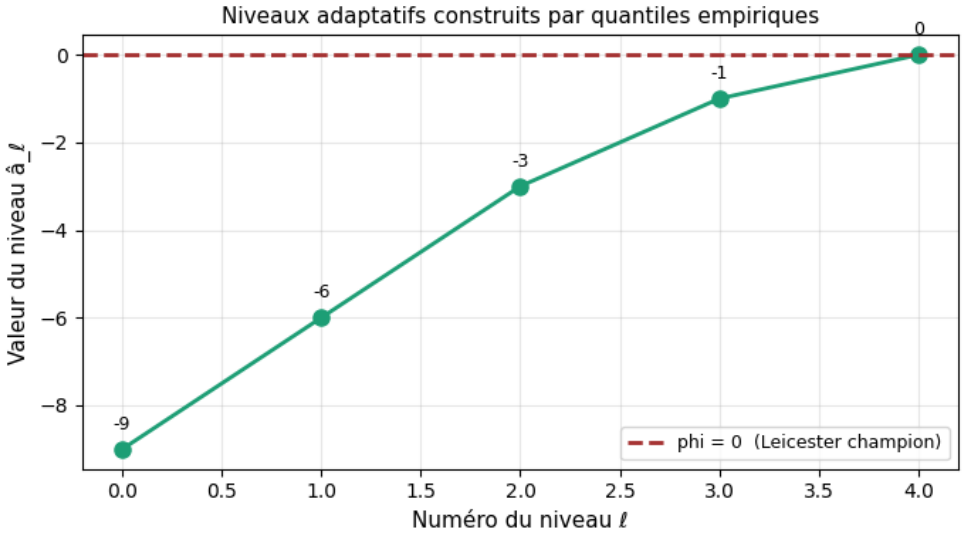


Figure 5 – Niveaux adaptatifs construits par quantiles empiriques. La ligne pointillée correspond au seuil final $\phi = 0$, c'est-à-dire à l'événement Leicester champion.

À chaque niveau, il faut simuler selon la loi conditionnelle

$$\mathcal{L}(X \mid \phi(X) \geq a_k).$$

Dans notre problème, cette loi conditionnelle n'est pas directement simulable. On utilise donc une chaîne de Markov dont les états sont des championnats complets.

À partir d'un championnat courant X, on construit une proposition X' en resimulant T matchs tirés au hasard parmi les 380 matchs du championnat. La proposition est ensuite acceptée uniquement si elle reste dans l'ensemble conditionnel :

$$X_{\text{new}} = \begin{cases} X', & \text{si } \phi(X') \geq a_k, \\ X, & \text{sinon.} \end{cases}$$

Ce mécanisme correspond au noyau tronqué

$$P_{a_k}(x, dx') = P(x, dx')\mathbf{1}_{\{\phi(x') \geq a_k\}} + \delta_x(dx')P(x, \{\phi < a_k\}).$$

Il garantit que la chaîne reste dans l'ensemble

$$\{\phi(X) \geq a_k\}.$$

Le paramètre T contrôle la taille des propositions. Un T faible produit des championnats très proches de l'état courant, tandis qu'un T élevé produit des propositions plus éloignées, mais potentiellement plus souvent rejetées.

Si l'algorithme construit K niveaux intermédiaires, et si les niveaux sont choisis de sorte que

$$\mathbb{P}(A_{k+1} \mid A_k) \simeq u,$$

alors

$$\mathbb{P}(A) \simeq u^K \, \mathbb{P}(A \mid A_K).$$

La dernière probabilité conditionnelle est estimée par

$$\widehat{p}_{\text{last}} = \frac{1}{n} \sum_{i=1}^{n} \mathbf{1}_{\{\text{Leicester champion dans } X_i\}},$$

où les X_i sont les championnats simulés au dernier niveau.

L'estimateur final est donc

$$\widehat{p}_{\text{split}} = u^K \, \widehat{p}_{\text{last}}.$$

Dans la simulation avec $u = 0.1$, $n = 50000$ et $T = 50$, on obtient

$$\widehat{p}_{\text{last}} = 0.33384.$$

Comme il y a $K = 4$ niveaux intermédiaires, l'estimateur vaut

$$\widehat{p}_{\text{split}} = 0.33384 \times 0.1^4 = 3.3384 \times 10^{-5}.$$

• Choix du paramètre T

Le paramètre T contrôle le nombre de matchs re-simulés pour construire une proposition dans la chaîne de Markov. Il joue donc un rôle important dans le mélange de la chaîne. Si T est trop petit, la proposition reste très proche du championnat courant : elle est souvent acceptée, mais les états successifs sont fortement corrélés. À l'inverse, si T est trop grand, la proposition modifie davantage le championnat, mais elle risque plus souvent de sortir du niveau courant et donc d'être rejetée.

Le choix de T repose ainsi sur deux critères complémentaires :

— le taux d'acceptation du noyau, qui ne doit être ni trop proche de 1, ni trop proche de 0 ;

— la stabilité de l'estimateur $\widehat{p}_{\text{split}}$, mesurée par sa variabilité sur plusieurs répétitions indépendantes.

Pour étudier ce compromis, nous testons plusieurs valeurs de T :

$$T \in \{10, 20, 50, 100, 200\}.$$

Pour chaque valeur de T, l'algorithme est répété plusieurs fois avec des graines aléatoires différentes. On calcule ensuite la moyenne et l'écart-type de l'estimateur obtenu, ainsi que le taux d'acceptation moyen du noyau.

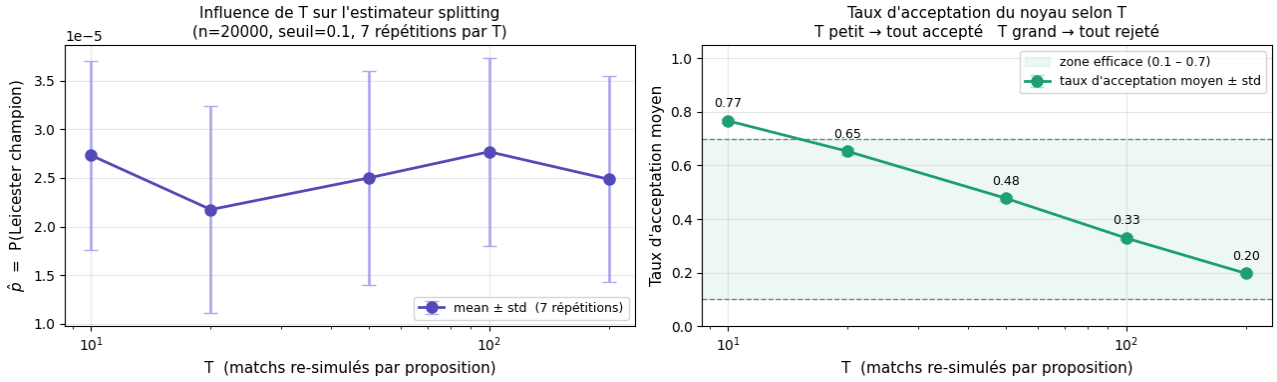


Figure 6 – Analyse du choix du paramètre T pour la méthode de splitting adaptatif. À gauche : influence de T sur l'estimateur $\widehat{p}_{\text{split}}$, représenté par sa moyenne et son écart-type sur plusieurs répétitions indépendantes. À droite : taux d'acceptation moyen du noyau de Markov en fonction de T.

La figure 6 montre que les petites valeurs de T donnent un taux d'acceptation élevé. Par exemple, $T = 20$ donne un taux d'acceptation moyen d'environ 0.65, ce qui se situe dans une zone raisonnable. Cependant, cette valeur conduit encore à une variabilité relativement importante de l'estimateur, avec un coefficient de variation empirique de 43.2.

La valeur $T = 50$ conserve un taux d'acceptation satisfaisant, tout en donnant un estimateur plus stable avev CV = 0.39. Nous retenons donc

$$T = 50$$

pour les simulations finales de la méthode de splitting adaptatif.

- Résultats numériques

Événement	$\widehat{p}_{\text{split}}$	**CV empirique**	**IC 95%**
A_1	2.6437×10^{-5}	39.0	$[2.1922 \times 10^{-5}, 3.0951 \times 10^{-5}]$
A_2	9.6670×10^{-9}	94.8	$[3.9855 \times 10^{-9}, 1.5348 \times 10^{-8}]$

Table 10 – Résultats numériques de la méthode de splitting adaptatif. Ici, A_1 désigne l'événement "Leicester champion", tandis que A_2 désigne l'événement complexe combinant Leicester champion, les clubs de Manchester hors podium, et Chelsea/Liverpool hors top 7.

Le CV passe de 39.0 pour A_1 à 94.8 pour A_2 : le splitting adaptatif, relativement stable pour l'événement "Leicester champion", devient beaucoup plus bruité pour l'événement complexe. Cette perte de précision s'explique par le caractère multi-contrainte de A_2, qui rend l'événement beaucoup plus rare et plus difficile à guider avec une seule fonction de progression.

4.6 Algorithme de la dernière particule

- **Principe**

L'algorithme de la dernière particule est une méthode adaptative de type multi-niveaux. Il s'applique dans le cadre statique où l'on cherche à estimer une probabilité rare de la forme

$$p = \mathbb{P}(S(X) > q),$$

où X est une variable aléatoire simulable, S est une fonction réelle associée à X, et q est un seuil fixé.

Dans notre problème, X représente un championnat complet, c'est-à-dire l'ensemble des résultats des 380 matchs. La fonction S est la fonction de progression ϕ définie précédemment, et le seuil final est

$$q = 0.$$

Ainsi,

$$p = \mathbb{P}(\phi(X) \geq 0) = \mathbb{P}(\text{Leicester gagne le championnat}).$$

Contrairement au splitting adaptatif par quantiles, où plusieurs niveaux sont construits en conservant une proportion fixée des particules, l'algorithme de la dernière particule avance niveau par niveau en supprimant uniquement la particule la moins avancée.

On maintient un système de n particules

$$X_1, \ldots, X_n,$$

où chaque particule est un championnat complet. À chaque itération j, on calcule les valeurs

$$\phi(X_1^{(j)}), \ldots, \phi(X_n^{(j)}).$$

Le niveau courant est défini comme le plus petit score parmi les particules :

$$L_j = \min_{1 \leq i \leq n} \phi(X_i^{(j)}).$$

La particule atteignant ce minimum est appelée la dernière particule. Elle est supprimée, puis remplacée par une copie d'une autre particule ayant dépassé le niveau courant.

Dans l'algorithme idéal, la nouvelle particule devrait être simulée exactement selon la loi conditionnelle

$$\mathcal{L}(X \mid \phi(X) > L_j).$$

Dans notre implémentation, cette simulation conditionnelle est approchée par une mutation de type MCMC. Plus précisément, on clone une particule déjà au-dessus du niveau courant, puis on lui applique T transitions du noyau de Markov défini précédemment. Les propositions qui descendent sous le niveau courant sont rejetées.

Ainsi, si X' est une proposition, la transition utilisée est

$$X_{\text{new}} = \begin{cases} X', & \text{si } \phi(X') > L_j, \\ X, & \text{sinon.} \end{cases}$$

Ce rejet garantit que la particule mutée reste dans l'ensemble conditionnel

$$\{\phi(X) > L_j\}.$$

L'algorithme est répété jusqu'à ce que toutes les particules dépassent le seuil final :

$$L_j \geq q = 0.$$

À ce moment, l'ensemble des particules a atteint l'événement rare.

À chaque itération, une particule parmi les n est éliminée. Le facteur de survie associé à une itération est donc

$$1 - \frac{1}{n}.$$

Si J désigne le nombre total d'itérations nécessaires pour atteindre le seuil final, l'estimateur de la probabilité rare est

$$\widehat{p}_{\mathrm{LP}} = \left(1 - \frac{1}{n}\right)^{J}.$$

Dans le cadre idéalisé, où la simulation conditionnelle est exacte, cet estimateur possède une fluctuation asymptotique connue :

$$\sqrt{n}\,\frac{\widehat{p}_{\mathrm{LP}} - p}{p} \Longrightarrow \mathcal{N}(0, -\log p).$$

On utilise donc l'approximation

$$\mathrm{CV}(\widehat{p}_{\mathrm{LP}}) \simeq \frac{\sqrt{-\log p}}{\sqrt{n}},$$

où CV désigne le coefficient de variation, c'est-à-dire le rapport entre l'écart-type et la moyenne.

Dans notre implémentation, cette formule est utilisée comme indicateur théorique. Elle reste une approximation, car la nouvelle particule n'est pas simulée exactement sous la loi conditionnelle : elle est obtenue par une mutation MCMC de longueur finie T.

- **Choix du nombre de particules n**

Dans l'algorithme de la dernière particule, le paramètre principal est le nombre de particules n. Il contrôle directement le compromis entre précision statistique et coût de calcul. En effet, dans le cadre théorique idéal, le coefficient de variation de l'estimateur vérifie approximativement

$$\mathrm{CV}(\widehat{p}_{\mathrm{LP}}) \simeq \frac{\sqrt{-\log p}}{\sqrt{n}}.$$

Ainsi, lorsque n augmente, la variabilité relative de l'estimateur diminue en ordre $1/\sqrt{n}$. En contrepartie, le coût de calcul augmente, car l'algorithme manipule davantage de particules et nécessite en moyenne plus d'itérations.

Pour étudier ce compromis, nous testons plusieurs valeurs de n :

$$n \in \{100, 200, 500, 1000, 2000\}.$$

Pour chaque valeur de n, l'algorithme est répété plusieurs fois avec des graines aléatoires différentes. On calcule ensuite la moyenne de l'estimateur, son écart-type, son coefficient de variation empirique

$$\mathrm{CV}_{\mathrm{emp}} = \frac{\mathrm{std}(\widehat{p})}{\mathrm{mean}(\widehat{p})},$$

le nombre moyen d'itérations J, ainsi que la durée totale de calcul.

n	$\mathrm{mean}(\widehat{p})$	$\mathrm{std}(\widehat{p})$	**CV**	**Durée (s)**
100	5.4733×10^{-4}	1.9394×10^{-4}	35.4	23.1
200	5.0088×10^{-4}	1.0695×10^{-4}	21.4	35.5
500	5.8206×10^{-4}	1.2969×10^{-4}	22.3	89.4
1000	5.4744×10^{-4}	7.5894×10^{-5}	13.9	179.3
2000	5.5833×10^{-4}	8.8441×10^{-5}	15.8	370.0

Table 11 – Influence du nombre de particules n sur l'algorithme de la dernière particule. Pour chaque valeur de n, on reporte la moyenne de l'estimateur, son écart-type, le coefficient de variation empirique et la durée totale de calcul.

La Figure 7 complète ce tableau en représentant simultanément le coefficient de variation empirique et le temps de calcul en fonction de n.

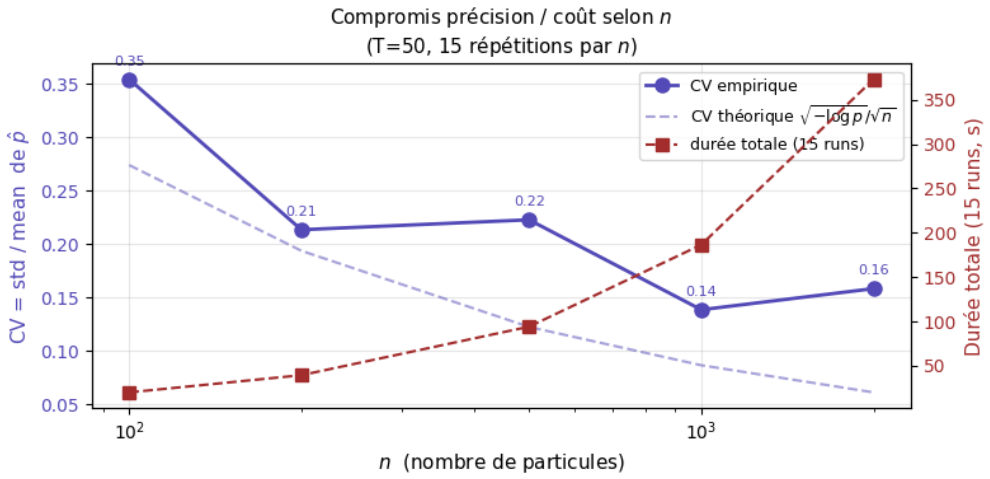


Figure 7 – Compromis précision/coût selon le nombre de particules n pour l'algorithme de la dernière particule. La courbe violette représente le coefficient de variation empirique, tandis que la courbe rouge représente la durée totale de calcul.

On observe que le passage de $n = 100$ à $n = 200$ réduit fortement le coefficient de variation, qui passe de 35.4 à 21.4. En revanche, augmenter davantage n améliore la stabilité de manière plus progressive, au prix d'un coût de calcul nettement plus important. Par exemple, $n = 1000$ donne le plus faible coefficient de variation observé, mais demande environ 190 secondes, contre environ 40 secondes pour $n = 200$.

Dans notre étude, nous retenons le plus petit n donnant un coefficient de variation inférieur à 0.3. Ce critère conduit à choisir

$$n = 200.$$

Ce choix permet d'obtenir un estimateur suffisamment stable tout en gardant un coût de calcul raisonnable. Pour les simulations finales,

• Résultats numériques

Après l'étude du choix du nombre de particules, nous appliquons l'algorithme de la dernière particule à l'événement principal

$$A_1 = \{\text{Leicester champion}\}.$$

Nous retenons

$$n = 200, \qquad T = 50.$$

L'algorithme est répété plusieurs fois avec des graines aléatoires différentes afin d'estimer la variabilité de l'estimateur.

Méthode	$\widehat{p}$	**CV empirique**	**IC 95%**
Dernière particule, A_1	5.0840×10^{-4}	24.0	$[4.5483 \times 10^{-4}, 5.6197 \times 10^{-4}]$

Table 12 – Résultat numérique de l'algorithme de la dernière particule pour l'événement $A_1 = \{\text{Leicester champion}\}$.

Le tableau 12 montre que l'algorithme de la dernière particule fournit une estimation de l'ordre de

$$5.08 \times 10^{-4}.$$

Le coefficient de variation empirique vaut 0.240, ce qui indique une variabilité plus faible que celle obtenue avec le splitting adaptatif sur l'événement principal, elle donne aussi des résultats plus cohérents avec ceux de l'IS.

5 ANALYSE COMPARATIVE DES MÉTHODES

5.1 Critères de comparaison

Pour comparer les différentes méthodes d'estimation, nous utilisons plusieurs critères complémentaires. Le premier est la valeur estimée de la probabilité, qui permet de comparer les ordres de grandeur obtenus. Le deuxième est le coefficient de variation empirique,

$$\mathrm{CV} = \frac{\mathrm{std}(\widehat{p})}{\mathrm{mean}(\widehat{p})},$$

qui mesure la variabilité relative de l'estimateur. Un CV faible indique un estimateur plus stable. Nous considérons également l'intervalle de confiance à 95%, ainsi que le coût de calcul et la sensibilité aux paramètres numériques de chaque méthode.

5.2 Comparaison sur l'événement Leicester champion

Le tableau suivant regroupe les résultats obtenus pour l'événement principal

$$A_1 = \{\text{Leicester champion}\}.$$

Méthode	$\widehat{p}$	**CV**	**IC 95%**	**Paramètre principal**
Monte Carlo naïf	8.0×10^{-5}	≈ 50	$[1.6 \times 10^{-6}, 1.6 \times 10^{-4}]$	$n = 50000$
Importance Sampling	1.197×10^{-4}	≈ 6	$[1.14 \times 10^{-4}, 1.26 \times 10^{-4}]$	$c \simeq 3$
Splitting adaptatif	2.6437×10^{-5}	39.0	$[2.1922 \times 10^{-5}, 3.0951 \times 10^{-5}]$	$T = 50$
Dernière particule	5.0840×10^{-4}	24.0	$[4.5483 \times 10^{-4}, 5.6197 \times 10^{-4}]$	$n = 200,\ T = 50$

Table 13 – Comparaison des méthodes pour l'estimation de la probabilité que Leicester gagne le championnat.

Le Monte Carlo naïf donne une première référence, mais il reste très instable : seuls quelques hits sont observés sur 50000 simulations, ce qui conduit à un intervalle de confiance très large.

L'échantillonnage préférentiel est la méthode la plus stable pour A_1. Le tilt appliqué à Leicester augmente la fréquence de l'événement, tout en corrigeant le biais par le rapport de vraisemblance.

Le splitting adaptatif fournit une estimation plus faible, avec un coefficient de variation plus élevé que l'importance sampling. Sa précision dépend fortement du choix de la fonction de progression et du mélange de la chaîne conditionnelle.

Enfin, l'algorithme de la dernière particule donne une estimation plus élevée que les autres méthodes.

5.3 Bilan

Le Monte Carlo naïf fournit une première référence, mais son intervalle de confiance est trop large pour conclure précisément. L'échantillonnage préférentiel optimisé est la méthode la plus stable pour l'événement principal A_1, avec un coefficient de variation nettement plus faible.

Le splitting adaptatif et l'algorithme de la dernière particule sont intéressants car ils s'inscrivent directement dans le cadre multi-niveaux du cours. Cependant, leurs résultats sont plus sensibles au choix de la fonction de progression et à la qualité de la simulation conditionnelle par MCMC. En particulier, l'écart entre l'estimation de la dernière particule et celles des autres méthodes indique que l'approximation de la loi conditionnelle joue un rôle important.

Ainsi, dans notre étude, l'importance sampling optimisé est retenu comme méthode de référence numérique pour A_1, tandis que les méthodes de splitting constituent une extension théorique et algorithmique utile pour explorer d'autres façons d'aborder les événements rares.

6
ESTIMATION DES VALEURS INTRINSÈQUES PAR L'ALGORITHME MM

6.1 Motivation

Dans la Section 3.4, les valeurs intrinsèques sont définies de manière ad hoc par $V_i = P_i^{\kappa}$, où P_i désigne le nombre de points obtenus lors de la saison précédente et $\kappa = 1{,}5$ est un exposant fixé arbitrairement. Nous proposons ici une alternative statistiquement fondée : estimer les V_i par *maximum de vraisemblance* à partir des résultats observés, en utilisant l'algorithme MM de Hunter2004.

6.2 Algorithme MM de Bradley–Terry

Rappelons que dans le modèle de Bradley–Terry, la probabilité que l'équipe i batte l'équipe j est

$$\mathbb{P}(i \text{ bat } j) = \frac{V_i}{V_i + V_j}. \tag{1}$$

En notant w_{ij} le nombre de victoires de i face à j et $N_{ij} = w_{ij} + w_{ji}$ le nombre total de confrontations décisives, la log-vraisemblance s'écrit

$$\ell(\mathbf{V}) = \sum_{i=1}^{N} \sum_{j=1}^{N} \bigl[w_{ij} \ln V_i - w_{ij} \ln(V_i + V_j) \bigr]. \tag{2}$$

L'algorithme MM Hunter2004 maximise (2) par la mise à jour itérative

$$V_i^{(k+1)} = \frac{W_i}{\displaystyle\sum_{j \neq i} \frac{N_{ij}}{V_i^{(k)} + V_j^{(k)}}}, \qquad W_i = \sum_{j \neq i} w_{ij}, \tag{3}$$

suivie d'une renormalisation $\mathbf{V}^{(k+1)} \leftarrow \mathbf{V}^{(k+1)} / \sum_i V_i^{(k+1)}$. Sous la condition de connexité du graphe des confrontations (Hypothèse 1 de Hunter2004), la suite $\bigl(\mathbf{V}^{(k)}\bigr)$ converge vers l'unique estimateur du maximum de vraisemblance, quelle que soit l'initialisation.

6.3 Données d'entraînement

L'estimation est réalisée sur les résultats de Premier League **antérieurs à la saison 2015–16**, afin de respecter la causalité du problème, plus précisément sur les cinq saisons 2010–11 à 2014–15 (soit les cinq

saisons immédiatement précédant 2015–16). Cette fenêtre temporelle présente l'avantage de refléter les forces actuelles des équipes : les performances de Manchester United sous Sir Alex Ferguson (1993–2013) ne sont pas représentatives de la force de l'équipe en 2015.

Bournemouth et Watford n'ont aucun historique en Premier League sur la période 2010–2015. On leur attribue une valeur V_i égale à la moyenne des équipes de la moitié basse du classement estimé, ce qui constitue la convention la plus neutre.

6.4 Résultats

L'algorithme MM converge en **56 itérations** (log-vraisemblance finale : $\ell(\hat{\mathbf{V}}) = -498{,}27$) . Le Tableau 14 présente les $\hat{V}_i$ estimés pour les 20 équipes de la saison 2015–16 .

Table 14 – Valeurs intrinsèques $\hat{V}_i$ estimées par l'algorithme MM, normalisées de sorte que $\sum_i \hat{V}_i = 1$.

Rang	Équipe	$\hat{V}_i$
1	Manchester City	0,1333
2	Manchester United	0,1234
3	Chelsea	0,1124
4	Arsenal	0,0962
5	Tottenham	0,0717
6	Liverpool	0,0658
7	Everton	0,0553
8	Southampton	0,0352
9	Stoke	0,0336
10	Newcastle	0,0297
11	West Brom	0,0292
12	Crystal Palace	0,0284
13	Swansea	0,0268
14	Bournemouth	0,0248
15	Watford	0,0248
16	Sunderland	0,0242
17	Norwich	0,0241
18	Aston Villa	0,0221
19	West Ham	0,0202
20	**Leicester**	**0,0185**

Lecture des résultats. Leicester est classé **dernier** ($\hat{V}_i = 0{,}0185$), ce qui est cohérent avec son statut d'équipe ayant frôlé la relégation lors de la saison 2014–15 (41 points, 14ème).

Le Tableau 15 rapporte les probabilités de victoire de Leicester face à chacun de ses adversaires, pour les deux cas.

Comparaison avec le modèle ad hoc $V_i = P_i^{\kappa}$. Pour quantifier l'écart entre les deux approches, nous régressons $\ln \hat{V}_i$ sur $\ln P_i$ (points 2014–15) :

$$\ln \hat{V}_i = \alpha + \kappa_{\mathrm{MM}} \ln P_i + \varepsilon_i. \tag{4}$$

On obtient $\kappa_{\mathrm{MM}} \approx 2{,}23$ ($R^2 = 0{,}77$), contre $\kappa = 1{,}5$ dans le modèle ad hoc. Cela signifie que le modèle ad hoc *sous-estime* les écarts entre grandes et petites équipes : il attribue à Leicester une force relative trop élevée ($\hat{V}_i^{\mathrm{adhoc}} = 0{,}034$ contre $\hat{V}_i^{\mathrm{MM}} = 0{,}019$, soit un rapport de 0,55). La probabilité p_{LEI} estimée avec les V_i MM sera donc *plus faible* qu'avec $V_i = P_i^{1{,}5}$, ce qui renforce le caractère d'événement rare de la victoire de Leicester.

Table 15 – Probabilités $\mathbb{P}(\text{Leicester bat } X)$ selon le modèle BT avec $\hat{V}_i$ estimés par MM contre le modèle ad hoc. Les cinq grands favoris sont indiqués en gras.

Adversaire X	ad hoc	MM
Arsenal	27,9%	16,1%
Chelsea	24,4%	14,2%
Man City	26,7%	12,2%
Man United	29,9%	13,1%
Tottenham	32,9%	20,5%
Liverpool	33,8%	22,0%
Everton	41,8%	25,1%
Southampton	34,7%	34,5%
Newcastle	47,0%	38,4%
Aston Villa	52,2%	45,6%
Crystal Palace	41,0%	39,4%
Norwich	36,1%	43,4%
Sunderland	52,2%	43,3%
Stoke	38,0%	35,5%
Swansea	36,9%	40,9%
Watford	35,0%	42,7%
West Brom	43,6%	38,8%
West Ham	41,8%	47,8%
Bournemouth	34,5%	42,7%

6.5 Impact sur l'estimation de p_{LEI}

Nous comparons maintenant les estimations de $p_{\text{LEI}} = \mathbb{P}(\text{Leicester champion})$ obtenues avec les $\hat{V}_i$ issus du MM.

Monte Carlo naïf. Avec $n = 50\,000$, $100\,000$ et $200\,000$ simulations, l'estimateur Monte Carlo naïf ne produit aucun hit (aucune simulation où Leicester est champion) :

$$\hat{p}^{\,\text{MC}} = 0, \qquad n \in \{50\,000,\ 100\,000,\ 200\,000\}. \tag{5}$$

Ce résultat illustre directement les limites théoriques discutées à la Section 4.2 : avec les V_i MM, p_{LEI} est si faible qu'il faudrait

$$n \gtrsim \frac{1}{p_{\text{LEI}} \cdot \varepsilon^2} \tag{6}$$

simulations pour atteindre une précision raisonnable, avec $p_{\text{LEI}} \approx 4 \times 10^{-7}$ (voir ci-dessous). Même pour $\text{CV} \leq 100\,\%$, cela représente environ $2{,}5 \times 10^6$ simulations.

Échantillonnage préférentiel scalaire. On applique l'estimateur IS avec $c = 3$ (tilt sur Leicester uniquement) à $n = 50\,000$ simulations :

$$\hat{p}^{\,\text{IS}}_{\text{scal}} = 4{,}40 \times 10^{-7}, \qquad \text{IC}_{95\%} = \left[3{,}80 \times 10^{-7},\ 5{,}00 \times 10^{-7}\right], \qquad \text{CV} \approx 15{,}6\,\%. \tag{7}$$

Le CV de 15,6 % indique une estimation stable, ce qui montre que l'échantillonnage préférentiel reste efficace même avec des V_i plus contrastés.

Échantillonnage préférentiel vectoriel. On applique le tilt vectoriel structuré avec $c_{\text{Lei}} = 3$ et $c_{\text{big}} = 0{,}7$ (cinq grands favoris : Arsenal, Chelsea, Man City, Man United, Tottenham) à $n = 10\,000$ simulations :

$$\hat{p}^{\text{IS}}_{\text{vect}} = 3{,}68 \times 10^{-7}, \qquad \text{IC}_{95\%} = \left[2{,}96 \times 10^{-7},\ 4{,}40 \times 10^{-7}\right], \qquad \text{CV} \approx 9{,}95\,\%. \tag{8}$$

Avec cinq fois moins de simulations, le CV descend de 15,6 % à 9,95 % : le tilt sur les adversaires améliore significativement l'efficacité de l'estimateur.

Synthèse et comparaison. Le Tableau 16 résume les estimations obtenues avec les deux jeux de V_i.

Table 16 – Comparaison des estimations de p_{LEI} selon le jeu de valeurs intrinsèques utilisé. IS scal. : $c = 3$, $n = 50\,000$; IS vect. : $c_{\text{Lei}} = 3$, $c_{\text{big}} = 0{,}7$, $n = 10\,000$.

Valeurs V_i	Méthode	$\hat{p}$	IC 95 %	CV
$P_i^{1,5}$ (ad hoc)	IS scal. ($c = 3$)	$1{,}20 \times 10^{-4}$	$[1{,}14,\ 1{,}26] \times 10^{-4}$	$\approx 6\,\%$
	IS vect.	$1{,}19 \times 10^{-4}$	$[1{,}09,\ 1{,}29] \times 10^{-4}$	$\approx 9{,}5\,\%$
$\hat{V}_i^{\text{MM}}$ (MM)	IS scal. ($c = 3$)	$4{,}40 \times 10^{-7}$	$[3{,}80,\ 5{,}00] \times 10^{-7}$	$\approx 15{,}6\,\%$
	IS vect.	$3{,}68 \times 10^{-7}$	$[2{,}96,\ 4{,}40] \times 10^{-7}$	$\approx 9{,}95\,\%$

Les $\hat{V}_i^{\text{MM}}$ conduisent à une probabilité environ **300 fois plus faible** que le modèle ad hoc (4×10^{-7} contre $1{,}2 \times 10^{-4}$). Cet écart s'explique par le κ implicite plus élevé (2,23 contre 1,5), qui accentue l'écart de force entre Leicester et les grands favoris. Les deux estimations restent cohérentes avec le message principal du rapport : la victoire de Leicester constitue un événement d'une rareté exceptionnelle, dont la probabilité se situe entre 10^{-7} et 10^{-4} selon la modélisation retenue pour les forces intrinsèques.

7 CONCLUSION ET PERSPECTIVES

Ce projet nous a permis d'étudier l'estimation de probabilités rares dans un modèle probabiliste simplifié de championnat de football. À partir d'un modèle de Bradley–Terry, nous avons simulé des saisons complètes de Premier League et estimé la probabilité que Leicester devienne champion, ainsi que des événements plus complexes liés à l'effondrement simultané de plusieurs grands clubs.

La méthode de Monte Carlo naïf fournit une première estimation, mais elle montre rapidement ses limites : l'événement étudié est trop rare pour être estimé précisément avec un budget de simulation raisonnable. L'échantillonnage préférentiel améliore fortement la situation en augmentant artificiellement la force de Leicester, puis en corrigeant cette modification par un rapport de vraisemblance. Pour l'événement principal A_1, cette méthode est la plus stable parmi celles étudiées.

Les méthodes de splitting offrent une approche différente. Le splitting adaptatif multi-niveaux permet de construire automatiquement des niveaux intermédiaires par quantiles empiriques, puis de simuler conditionnellement à ces niveaux à l'aide d'un noyau de Markov tronqué. Cette méthode donne des résultats exploitables pour l'événement principal, mais devient plus bruitée sur l'événement complexe A_2, dont la réalisation impose plusieurs contraintes simultanées.

L'algorithme de la dernière particule constitue une extension naturelle du splitting adaptatif et il est bien adapté au cadre théorique des événements rares. Cependant, dans notre application, la simulation conditionnelle exacte n'est pas disponible et doit être approchée par une mutation MCMC de longueur finie. Les résultats numériques montrent que cette méthode est sensible au choix du noyau et au mélange de la chaîne. Elle mérite donc une analyse plus approfondie avant d'être utilisée comme estimateur de référence.

Au final, l'importance sampling optimisé apparaît comme la méthode la plus robuste pour l'événement principal. Le splitting adaptatif et la dernière particule sont néanmoins intéressants car ils relient directement le problème au cadre théorique des méthodes multi-niveaux vues en cours. Ils mettent aussi en évidence une

difficulté centrale : pour les événements complexes, il ne suffit pas de favoriser Leicester ; il faut construire une fonction de progression capable de guider simultanément plusieurs contraintes de classement.

Plusieurs améliorations sont possibles. On pourrait d'abord raffiner le modèle sportif en introduisant les matchs nuls, l'avantage à domicile ou une estimation plus réaliste des valeurs intrinsèques des équipes. On pourrait aussi améliorer les méthodes de splitting en construisant une fonction de progression plus adaptée à l'événement complexe A_2.